

Ocena modelu: dokładność wieku i lokalizacji przyrostów

Poniżej przedstawiono wyniki oceny modelu DINOv2 w dwóch zadaniach: określaniu **wieku ryby** oraz **lokalizacji pierścieni rocznych** na otolicie. Zestawiono kolejne próby poprawy lokalizacji wraz z wnioskami i kierunkami dalszej pracy.

0,75 -0,85 lat

błąd wieku (MAE), stabilny w 22 niezależnych treningach

~85%

trafień w granicach ± 1 rok —
wynik użyteczny w praktyce

6-14_x

tyle mniej precyzyjny jest
model niż odczyt ekspercki w
pozycji pierścienia (27-60 px
vs 4,3 px)


Co się udało — wiek ryby

CORAL + MIL na DINOv2, licząc wyłącznie z etykiety wieku

Głowica CORAL (uporządkowane pytania „starszy niż X lat?”) osiągnęła dobry wynik już w pierwszym udanym biegu (Run 1) i **od tamtej pory ani razu nie została zepsuta** — mimo dziesięciu prób zmiany głowicy lokalizacji obok niej. To zasługa architektonicznego odsprężnięcia (stop-gradient): eksperymenty z pozycją przyrostów fizycznie nie mogą wpłynąć na wynik wieku.

Błąd wieku (MAE) w 22 kolejnych treningach

Każda kropka = jeden pełny bieg treningowy, w kolejności chronologicznej (Run 1–22). Zacieniony pas: rozstęp międzykwartylowy (IQR) — środkowe 50% wszystkich wyników, 0,80–0,84 roku.



najlepszy wynik: **0,751** ostatni bieg (seed 7): **0,829** rozstęp całej serii: **0,10**

pas w tle: **IQR, 25.–75. percentyl**

Pełne zestawienie — co zmieniał każdy z 22 biegów

Realna ocena pozycji względem adnotacji eksperckich (zbiór ZEGAR) istnieje dopiero od biegu 16 (Run N) — metodologia ZEGAR powstała po tym biegu. Wcześniejsze 15 biegów miało tylko wewnętrzną miarę-proxy, uznaną w projekcie za niewiarygodną i dlatego tu pominiętą.

#	BIEG	CO SIĘ ZMIENIŁO	MAE (WIEK)	OCENA POZYCJI (ZEGAR)
1	baseline	pierwszy udany bieg — CORAL + MIL, punkt odniesienia dla wieku	0,789	—
2	radial-spread	kara rozpychająca aktywne fragmenty promieniowo — porażka, wycofana	0,838	—
3	powtórka baseline	ta sama receptura co bieg 1, bez zmian — ujawniła stochastykę treningu (→ wprowadzono seedowanie)	0,853	—
4	odsprzęgnięta density	wprowadzona osobna głowica gęstości (stop-gradient) — świeci na krawędziach/odbłaskach, nie na pierścieniach	0,807	—
5	backbone z rejestrami + TV	backbone DINOv2 wariant „z rejestrami” + prior gładkości przestrzennej — najlepszy wiek w projekcie; density nieaktywna 22 z 26 epok	0,751	—

#	BIEG	CO SIĘ ZMIENIŁO	MAE (WIEK)	OCENA POZYCJI (ZEGAR)
6	rejestry, TV=0	jak bieg 5, wyłączony prior gładkości, dodana bramka dojrzałości density — density budzi się, ale wiek się pogarsza (konflikt wiek↔density)	0,800	—
7	naprawa liczenia	bez nowego treningu — poprawiono błąd grupowania pików kandydatów (liczba przyrostów = wiek)	0,807	—
8	maskowanie tła	tło otolitu maskowane przed podaniem do modelu + dwa osobne checkpointy (wiek / density) — density budzi się wcześniej (epoka 10)	0,7993	—
9	poprawki density_head	LayerNorm, wyższy LR, TV wewnątrz głowicy density + wyższa rozdzielczość mapy — wiek bit-identyczny z biegiem 8	0,7993	—
10	wyższa rozdzielczość (966px)	pełny trening (CORAL+MIL+density) na obrazach 966px zamiast 518px — wiek pogorszył się, pierwszy realny koszt w serii	0,824	—
11	prior współśrodkowości, w=0,1	nowy człon straty karzący brak współśrodkowości pierścienia, najostrożniejsza waga — zero mierzalnego efektu	0,7993	—
12	prior współśrodkowości, w=1,0	ta sama zmiana, waga 10× wyższa — wynik bit-identyczny	0,7993	—
13	prior współśrodkowości, w=10,0	waga 100× wyższa od biegu 11 — wynik nadal bit-identyczny; ten kierunek zamknięty	0,7993	—
14	izolacja: sam prior	sam prior współśrodkowości, bez mechanizmu uwagi — density budzi się normalnie, ale nadal głównie na krawędzi otolitu	0,8018	—
15	izolacja: sama uwaga	sam mechanizm uwagi, bez priora współśrodkowości — density nieaktywna przez cały trening	0,8362	—

#	BIEG	CO SIĘ ZMIENIŁO	MAE (WIEK)	OCENA POZYCJI (ZEGAR)
16	Run N	nowa architektura: kodowanie pozycyjne (promień×kąt) + lokalna uwaga w oknie 45° — density pierwszy raz naprawdę ożyła ; model przewyższył metodę tradycyjną — model referencyjny	0,8498	tak — patrz wyżej
17	Próba 1	+ prior współśrodkowości na architekturze biegu 16	0,8498	tak — patrz wyżej
18	Próba 2	okno lokalnej uwagi poszerzone z 45° do 90°	0,8353	tak — patrz wyżej
19	Próba 3	osłabiona wymuszona punktowość mapy density, wzmocniony prior gładkości	0,8353	tak — patrz wyżej
20	Próba 4	zmniejszona rozdzielczość promieniowa uwagi, mniej harmonik Fouriera	0,8362	tak — patrz wyżej
21	Opcja A, seed 42	dodatkowa strata pozycyjna na 30/42 zdjęciach ZEGAR, dołożona do głównego treningu	0,8109	tak — patrz wyżej
22	Opcja A, seed 7	identyczna receptura jak bieg 21 — jedyna różnica: ziarno losowości	0,829	tak — patrz wyżej

Poza tą listą: dwa warianty „Opcji B” (mała głowica trenowana wyłącznie na 42 zdjęciach, zamrożony backbone) na wykresie i w tabeli wyżej — to osobny, mniejszy eksperyment, nie pełny retrening głównego modelu, więc nie ma własnego wpisu MAE w tej liście.

Co się nie udało — pozycja przyrostów

dziesięć prób, dwie strategie, jeden trwały sufit

Odsprzęgnięta głowica gęstości (density head) uczy się liczyć przyrosty ze samej etykiety wieku — bez żadnej ręcznej adnotacji pozycji. Kierunek odczytu (oś pomiaru) jest wyznaczany w pełni automatycznie: start zawsze w geometrycznym środku otolitu

(jądrze), a koniec — w punkcie konturu, którego profil jasności wskazuje najwięcej potencjalnych pierścieni. Wcześniejsza reguła (zgodna z konwencją ICES) wybierała po prostu najdalszy punkt konturu od jądra. Po zmianie reguły wyboru osi (wciąż automatycznej, bez ręcznej ingerencji) model **po raz pierwszy w projekcie przewyższył dokładnością metodę tradycyjną** przetwarzania obrazu, ale pozostaje ok. **6× mniej precyzyjny niż zgodność między dwoma niezależnymi odczytami eksperckimi**. Cztery próby przestrojenia architektury nie ruszyły tego wyniku; dwie próby dołożenia realnych pozycji (42 zdjęcia „ZEGAR”) dały wynik od „gorzej niż losowe zgadywanie” po „silnie zależny od losowego ziarna inicjalizacji”.

Odległość od prawdziwej pozycji pierścienia (px; niższa wartość = lepszy wynik; skala logarytmiczna)

Zestaw referencyjny: 42 otolity ocenione niezależnie przez dwóch doświadczonych ekspertów (zbiór „ZEGAR”)

PUNKTY ODNIESIENIA

Zgodność odczytów eksperckich

dwa niezależne odczyty eksperckie (KK vs SS)

4,3 px poziom odniesienia

Metoda tradycyjna (OpenCV)

wykrywanie krawędzi, bez uczenia

122,9 px bity przez model >4×

FAZA 1 – STROJENIE ARCHITEKTURY DENSITY (4 PRÓBY)

Run N

model referencyjny

27,9 px punkt odniesienia

+ prior współśrodkowości

Próba 1 (Zmiana B)

27,3 px szum, bez zmian

Szersze okno uwagi

Próba 2 (45°→90°)

26,5 px szum, bez zmian

Słabsza punktowość straty

Próba 3 (wagi density)

27,6 px szum, bez zmian

Mniej binów promienia

Próba 4 (ostatnia dźwignia)

55,4 px regres 2,4×

FAZA 2 – NADZÓR POZYCYJNY: REALNE POZYCJE Z 42 ZDJĘĆ „ZEGAR”

Opcja B, bez kanonizacji

Wariant 1 (mała głowica, 42 zdjęcia)

503 px gorzej niż loso

Opcja B, kanonizacja osi

Wariant 2 (obróć do stałej orientacji)

338 px remis z losowym

Opcja A, seed 42

Wariant 1 (pół-słaby nadzór, 12 obrazów spoza treningu)

31,5 px remis na medianie

Opcja A, seed 7

Wariant 2 (ta sama recepta, inny seed)

60,2 px głowica martwa 37/37 epok

5 10 25 50 100 250 500 1000 px

Faza 1 i „Opcja B”: wszystkie 42 zdjęcia ZEGAR (skorygowany zestaw referencyjny); Opcja B oceniana 3-krotną walidacją krzyżową. Opcja A (oba warianty): 12 zdjęć celowo wykluczonych z treningu — jedyne uczciwe porównanie dla tej metody. Run N na tych samych 12 zdjęciach: 27,0 px — praktycznie bez zmian względem wszystkich 42.

Co dokładnie różniło poszczególne próby

Zmiana opisana zawsze względem modelu referencyjnego (Run N). Dwa punkty odniesienia (zgodność ekspercka, metoda tradycyjna) pominięte — nie są wariantami modelu.

METODA	CO DOKŁADNIE SIĘ ZMIENIŁO
Run N	model referencyjny — kodowanie pozycyjne (promień×kąt) + lokalna uwaga w oknie 45°
Próba 1	dodatkowy człon straty karzący brak współśrodkowości pierścienia (waga 1,0)
Próba 2	okno lokalnej uwagi poszerzone z 45° do 90°
Próba 3	osłabiona wymuszona punktowość mapy density (waga 1,0→0,3), wzmocniony prior gładkości przestrzennej (waga 0,03→0,3)
Próba 4	zmniejszona rozdzielczość promieniowa uwagi (12→6 binów) i mniej harmonik Fouriera w kodowaniu pozycyjnym (4→2)
Opcja B, wariant 1	zupełnie inna metoda: mała, osobna głowica trenowana wyłącznie na 42 zdjęciach z realnymi pozycjami, backbone zamrożony
Opcja B, wariant 2	jak wariant 1, dodatkowo każde zdjęcie obrócone do stałej orientacji odczytu przed treningiem
Opcja A, wariant 1 (seed 42)	dodatkowa strata pozycyjna na 30 z 42 zdjęć ZEGAR, dołożona do głównego treningu (~18 700 zdjęć); ziarno losowości: 42
Opcja A, wariant 2 (seed 7)	identyczna receptura jak wariant 1 — jedyna różnica: ziarno losowości 7

Ostatni rozdział: wpływ losowej inicjalizacji

seed 42 kontra seed 7 — identyczny kod i dane, różny wynik zależny wyłącznie od ziarna losowości

Jedyna różnica między dwoma biegami Opcji A to ziarno losowości (seed) sterujące inicjalizacją wag i kolejnością danych. Wszystko inne — architektura, dane, waga nowego członu straty — było identyczne. Wynik: jeden bieg „obudził się” i wyszedł na remis z modelem referencyjnym; drugi zmarł od pierwszej do ostatniej epoki.

Co dokładnie oznacza „głowica się nie budzi”? Density head ocenia każdy fragment obrazu liczbą 0–1 („na ile to miejsce wygląda na pierścień”). Strata wymusza dwie rzeczy naraz: suma tych ocen ma odpowiadać wiekowi ryby, a garstka najwyższej ocenionych

fragmentów ma zostać skoncentrowana blisko wartości 1, reszta blisko 0 (tzw. strata koncentracji) — tak powstają wyraźne, policzalne piki zamiast rozmytej mgły. Jeśli jednak na starcie treningu żaden fragment nie wybija się choćby nieznacznie ponad resztę, strata koncentracji nie ma punktu zaczepienia: mapa zostaje płaska i bliska zeru przez cały trening, bo brakuje sygnału mówiącego, który fragment powinien wygrać. To, czy taki wyróżniający się punkt pojawi się od pierwszych epok, zależy od losowej inicjalizacji wag głowicy — stąd wrażliwość wyniku na samo ziarno losowości (seed). Możliwe, nieprzetestowane w tym projekcie kierunki naprawy: rozgrzewka z wyższym mnożnikiem LR dla samej głowicy w pierwszych epokach, krótki etap wstępny trenujący ją osobno na zróżnicowanie, albo prosta bramka „restart z innym seedem, jeśli po N epokach `density_active=0`”.

SEED 42 — REMIS

Głowica się obudziła

31,5 px

średni błąd, 12 obrazów spoza treningu

@16

epoka wybudzenia

Aktywność mapy gęstości wzrosła z 0 do 3,3–4,4 od epoki 16 i utrzymała się do końca — normalny przebieg, porównywalny z modelem referencyjnym.

SEED 7 — PORAŻKA

Głowica nigdy się nie obudziła

60,2 px

średni błąd, 12 obrazów spoza treningu


0/37

epok z aktywnością

Aktywność mapy gęstości pozostała dokładnie zerowa przez wszystkie 37 epok. Bramka dojrzałości poddała się po 25 epokach oczekiwania.

Aktywność głowicy density w kolejnych epokach treningu

Prosto z logu treningu (``train.log``) — bez interpretacji



To przewartościowuje wynik `seed=42`: nie był dowodem, że dołożenie realnych pozycji *pomaga* tak samo jak Run N. Był jednym udanym losowaniem. **Najważniejszy wniosek nie dotyczy tego, czy nowa strata działa — dotyczy tego, że zbieżność samej głowicy**

silnie zależy od przypadku, niezależnie od tego, co się na niej dokłada. To podważa też pewność co do Run N samego w sobie, nigdy nie testowanego na drugim seedzie.

Wszystkie liczby

ta sama tabela w formie do skanowania

METODA	ETAP	PX (ŚREDNIA)	PODSTAWA	WERDYKT
Zgodność odczytów eksperckich (KK vs SS)	—	4,3	42 zdj.	—
Metoda tradycyjna (OpenCV)	—	122,9	42 zdj.	bity przez model
Run N (referencyjny)	model referencyjny	27,9	42 zdj.	odniesienie
+ prior współśrodkowości	próba 1	27,3	42 zdj.	szum
Szersze okno uwagi	próba 2	26,5	42 zdj.	szum
Stabsza punktowość straty	próba 3	27,6	42 zdj.	szum
Mniej binów promienia	próba 4	55,4	42 zdj.	regres 2,4×
Opcja B, bez kanonizacji	wariant 1	503,2	42 zdj., 3-fold	gorzej niż losowo
Opcja B, kanonizacja osi	wariant 2	337,7	42 zdj., 3-fold	remis z losowym
Opcja A, seed 42	wariant 1	31,5	12 obrazów spoza treningu	remis na medianie
Opcja A, seed 7	wariant 2	60,2	12 obrazów spoza treningu	głowica martwa

Alternatywy — co dalej, jeśli projekt ma być kontynuowany

żadna z nich nie jest kolejnym krokiem tej samej drabiny — to inne drabiny

REKOMENDACJA DOMYŚLNA

Zostać przy Run N, zamknąć strojenie

Wiek — produkcyjnie gotowy. Density — pogładowa mapa „gdzie mniej więcej patrzeć”, nie twarda pozycja pierścienia. Technik i tak weryfikuje wzrokiem.

Nadzorowana detekcja (U-Net / keypoints)

Domenowy standard z literatury rybackiej. Wymaga małego, ręcznie oznaczonego zbioru — teraz bardziej uzasadniona, bo problem to nie brak tuningu, tylko niestabilna zbieżność.

Większy zbiór „ZEGAR”

Więcej niż 42 zdjęcia z realnymi pozycjami zmniejszyłoby zarówno szum oceny, jak i ryzyko wylosowania martwej głowicy przy silniejszym nadzorze.

Tania bramka na przyszłość

Sprawdzać `density_active` w logu treningu (30 sekund) przed zaufaniem jakimkolwiek wynikowi ZEGAR — zamiast 25-minutowego `re-score'u` za każdym razem.

Podsumowanie zamyka wątek lokalizacji przyrostów w obecnej formie: dalsze losowe powtórki Opcji A nie są planowane — para seed 42/seed 7 już odpowiedziała na ważniejsze pytanie (wariancja inicjalizacji dominuje nad sygnałem z członu straty) lepiej, niż zrobiłby to trzeci bieg.

pełna kronika (38 sekcji) → `outputs/DINO_proces.md`

ten wynik, pełny opis → `plans and summaries/01.09_zegar_semi_weak_seed7_wyniki.md`

poprzedni artefakt (Run N vs Opcja A, seed 42) → claude.ai/code/artifact/96c5ae39...